

Ejercicios de minería de texto

1. A partir de los datos usados en clase para el reconocimiento del autor del tweet:
 - a. Seleccione los 3 autores más frecuentes.
 - b. Divida los datos en cuatro categorías, una para cada uno de los autores seleccionados y la otra para los tweets que sean de otro autor.
 - c. Divida en train y test
 - d. Genere un modelo que reconozca los autores
 - e. Calcule la tasa de aciertos por autor
 - f. Grafique la tasa de aciertos por autor vs la frecuencia relativa de cada autor
 - g. Genere la matriz de confusión
2. Genere las nubes de palabras para las cuatro categorías del ejercicio 1.
3. A partir de los libros utilizados en la clase práctica tomados del proyecto gutemberg:
 - a. Divida en train y test
 - b. Clasifique los de train y test en historia, cocina y otros
 - c. Construya un modelo predictivo sobre los datos de train para clasificar en historia, cocina y otros sin realizar la limpieza del texto
 - d. Aplique el modelo predictivo a los datos de test
 - e. Calcule la tasa de aciertos por categoría
 - f. Realice la limpieza del texto y reconstruya el modelo predictivo ahora sobre los textos limpios
 - g. Aplique el modelo predictivo a los datos de test
 - h. Calcule la tasa de aciertos por categoría