

Guión práctico

Minería de texto

Agenda

- 1. Nube de palabras*
- 2. Clasificación supervisada*
- 3. Clasificación no supervisada*

Nube de palabras

Tenemos un texto

Queremos obtener

habertodamejorseã±sanchoSiemprepuntopuesto habã-unas

palabra soldados

¿quéc:ahoraâ¿ pasadorey palabrasv istacabalodecã- gentesinocasi mãjs mientras dos
buensã-poderã± asã-ciento luego parte entonces historiatierra

casadespuesniã±dã-workrostromuchascosastrestalcaminos-noches

uerrahombressanparecã-ã© mitiempopuedeugaramigosf uerzapaso

hombremujerestarde muertemar tambiã©nilegarã±toelectronicmediodebe

hacercã±mot amilaaguaadijopareceamigomadresol diahoras quã©

maneraprojectpuebloallã-ver horaaã±ntãº salirã±aunverdadesspaã±dichojuan

hacergranfincadaquerã-tan pasarhecho quijotecapitã±nuz tenermanosmal

jovenmodo despuã©Smara-may aquelclar

gutenberg cielo usted nombre nuevo o selã±cora podã- oro vida nunca
cosa ciudad hablar espã±ales mundo pesar don pequeã±
cuanto

ãj

doã±w orkshjaã±f rente podra haciahacã-suelomanocercahizograndeaquellaunquesã© estã±causaagreement aquellos madridmujerfalmprimerahabã± vistoPUESaquellasibageneralpaã±s tenã- ojosprontodentrosaber

oundationpuertacaballerodecirdios buena lermisalgunahijodicenademomentoideamarcasomayordemã±sjuntSermismoallã±
v iejo padre

cabezamanuelcalle Vecesgrandeexistenciaaquã-solo mismaVEZ adjmã-cuatroademã±ssabã- segã±nmas

menos voz ã©ltodas bajo â¿quã© fuã©
maã¿sana â¿
bien

Nube de palabras

Cargo las librerías

library(tm)

library(wordcloud)

Nube de palabras

Cargo el corpus

```
docs <-  
Corpus(DirSource("d:/Users/ignacio/Dropbox/Curso  
Elearning Diplo en BI/MLP/Materiales/Minería de  
Texto/Libros"))
```

Nube de palabras

Limpio el corpus

```
toSpace <- content_transformer(function(x, pattern)  
{return (gsub(pattern, " ", x))})
```

```
docs <- tm_map(docs, toSpace, "-") docs <-  
tm_map(docs, toSpace, ":") docs <-  
tm_map(docs, removePunctuation)
```

Nube de palabras

Limpio el corpus (cont.)

```
docs <- tm_map(docs, toSpace, "'") docs  
<- tm_map(docs, toSpace, "\"") docs <-  
tm_map(docs, toSpace, "-") docs <-  
tm_map(docs, content_transformer(tolower)) docs <- tm_map(docs,  
removeNumbers)
```

Nube de palabras

Limpio el corpus (cont. 2)

```
docs <- tm_map(docs, removeWords, stopwords("english"))
```

```
docs <- tm_map(docs, removeWords, stopwords("spanish"))
```

```
docs <- tm_map(docs, stripWhitespace)
```

Nube de palabras

Construyo la matriz de palabras x documentos:

```
dtm <- DocumentTermMatrix(docs)
```

```
freq <- colSums(as.matrix(dtm))
```

```
ord <- order(freq,decreasing=TRUE)
```

Nube de palabras

Construyo la nube de palabras

```
freq2 <- freq[which(freq>=2000)]
```

```
wordcloud(names(freq2),freq2)
```

Nube de palabras

palabra soldados haber

mejor se a si siempre puesto casi unas

toda sancho punto **habã-**

ahoraâ¿ pasadorey palabrasv istacaballodecã- gentesino **mãjs** mientras dos

casa despuesbuenniã±sã-ãiquã©dã-workpoderostroaã±amormuchasasã-cosascierto luegotalcaminoguerrapartehombresparecã-entoncesmil**tiempo**puedehistorialugartierraamigosf uerzapaso
tres noche san

hombremujerestardepueblomuertemar tambiã©nllagarversã%loelectronicmediodebetã-ã³hacecã³mof amiliaverdadagua**dijo**dichopareceã©amigomadresol
quã©tan
granhorasdiafin

manerapasarcielo**projecthecho** allã-quijote horaaã³nlutzãº salirtenermanosaunmalespaã±modojuan **hacerdespuã©saquelcadaquerã-**

gutenberg
usted
cosa
ciudad
capitã¼n
seã±ora
hablar
espaã±toles
podã-
indios
oven
oro
mundo
pesar
viga
nunca
suerte
cuãnto
don
pequeã±
ã¼
doã±w Orkshijaã¼
uerpo
rentepobre
nombrehacã-haciasuelomanocercahizocabeza
grande
nuev

oaquellaunquesã©vecesgrandesestã¼causaaquello agreementmadrid**mujer**almaaquã¼-primerahabiasololadovistopuesaquellasibageneralmismaveZpaã-s

tenã-ojosprontodentroadjmã-saberf

oundationpuertacaballeroatuatrodecirademã¼sdiosbuena**sabã-terms**algunahijomarã-dicenadiesegã¼nmomentomasideaaarmascasomayordemã¼sjunto**sermism**

Oallã¼

v iejo padre calle

manuel existencia

menos voz **ã©**ltodas bajo â¿quã©fuã©

maã±ana **ã¼** bien

Clasificador supervisado

Cargo las librerías

```
library(tidyverse)
```

```
library(tidytext)
```

```
library(naivebayes)
```

```
library(tm)
```

```
library(caret)
```

Clasificador supervisado

Cargo los datos

```
setwd("d:/Users/ignacio/Dropbox/Curso Elearning  
Diplo en BI/MLP/Materiales/Minería de Texto")
```

```
download.file(url =  
"https://raw.githubusercontent.com/jboscomendoza/  
r_pubs/master/bayes_twitter/tuits_bayes.csv", destfile  
= "tuits.csv")
```

Clasificador supervisado

Cargo los datos (cont.)

```
tuits_df <- read.csv("tuits.csv", stringsAsFactors = F,  
fileEncoding = "latin1") %>% tbl_df
```

Clasificador supervisado

Cargo los datos (cont.)

```
tuits_df <- read.csv("tuits.csv", stringsAsFactors = F,  
fileEncoding = "latin1") %>% tbl_df
```

¿CON QUE SE COME?



Operador %>%:

Probamos:

`0 %>% cos()` Da:

1

Esto significa: $\cos(0)$ y, por supuesto, da 1

Operador %>%:

Probamos:

```
0 %>% cos() %>%  
sin() [1] 0.841471  
sin(1) [1] 0.841471
```

Definimos una función:

```
quitar_url <- function(texto) {  
  gsub("\\<http\\S*\\>/[0-9]", " ", texto)  
}
```

Separo y cuento las palabras:

```
tuits_df %>% unnest_tokens(input =  
  "text", output =  
    "palabra") %>% count(screen_name,  
status_id, palabra) %>% spread(key =  
palabra, value = n)
```

Otra función para crear la matriz:

```
crear_matriz <- function(tabla) {  
tabla %>% mutate(text =  
quitar_url(text)) %>%
```

```

  unnest_tokens(input = "text", output = "palabra") %>%
count(screen_name, status_id, palabra) %>%
spread(key = palabra, value = n) %>%   select(-
status_id)
}

```

Creo la matriz:

```

ejemplo_matriz <- tuits_df %>% mutate(screen_name =
ifelse(screen_name == "MSFTMexico", screen_name, "Otro"),
      screen_name = as.factor(screen_name)) %>%
crear_matriz

```

Función para elegir el usuario:

```
elegir_usuario <- function(nombres, usuario) {  
  as.factor(ifelse(nombres %in% usuario, nombres, "Otro"))  
}
```

Separo en entrenamiento y prueba:

```
set.seed(2001) ejemplo_entrenamiento <-  
sample_frac(ejemplo_matriz, .7) ejemplo_prueba <-  
setdiff(ejemplo_matriz, ejemplo_entrenamiento)
```


Función para crear los conjuntos:

```
crear_sets <- function(tabla, prop = .7) {  lista_sets  
<- list()  lista_sets$train <- sample_frac(tabla, prop)  
lista_sets$test <- setdiff(tabla, lista_sets[["train"]])  
  
  lista_sets  
}
```

Modelo y predicción:

```
ejemplo_modelo <- naive_bayes(formula = screen_name ~ .,  
  data = ejemplo_entrenamiento)
```

```
ejemplo_prediccion <- predict(ejemplo_modelo,  
  ejemplo_prueba)
```

Matriz de confusión:

```
confusionMatrix(ejemplo_prediccion,  
  ejemplo_prueba[["screen_name"]])
```

Automatizo modelo y predicción:

```
obtener_bayes <- function(lista_sets, objetivo = "screen_name") {  
  bayes_formula <- as.formula(paste0(objetivo, "~ .") )   bayes <-  
  list()
```

```

bayes$modelo <- naive_bayes(formula = bayes_formula, data =
  lista_sets[["train"]])
bayes$prediccion <- predict(object = bayes$modelo, newdata =
  lista_sets[["test"]])

bayes
}

```

Automatizo modelo y predicción:

```

obtener_bayes <- function(lista_sets, objetivo = "screen_name") {
  bayes_formula <- as.formula(paste0(objetivo, "~ .") )  bayes <-
  list()

  bayes$modelo <- naive_bayes(formula = bayes_formula, data =
    lista_sets[["train"]])

```

```
bayes$prediccion <- predict(object = bayes$modelo, newdata =  
  lista_sets[["test"]])
```

```
bayes  
}
```

Automatizo matriz de confusión:

```
mat_conf <- function(resultado, set_test) {  
  confusionMatrix(resultado[["prediccion"]],  
    set_test[["test"]][["screen_name"]])  
}
```

Salida gráfica:


```
ejemplo_conf <- confusionMatrix(ejemplo_prediccion,  
ejemplo_prueba[["screen_name"]])
```

```
plot(ejemplo_conf[["table"]])
```

Salida gráfica:

MSFTMexico

ejemplo_conf[["table"]]
Otro



¿Alguna pregunta?

Muchas Gracias