

Minería de Textos Y

Conversión de voz a texto Hay
información disponible

- Chats
- Mails
- Facebook
- Tweeter
- Libros digitalizados • Documentos corporativos

- etc, etc, etc.

¿Qué podemos hacer?

- Categorización de piezas de texto.
- Extracción de la información incluida en esos textos: hechos, acontecimientos, datos clave, relaciones entre ellos, etc.

- Establecimiento de asociaciones entre los datos extraídos de los textos.
- Extracción automática o supervisada de tópicos o temas

Entonces oímos una voz...

- Diálogos de calls centers
- Encuestas automatizadas
- IVRs activados por la voz
- Asistentes personalizados (Siri, Cortana) • Pilot associates
- Etc. etc. etc.

Minería de Textos

Algoritmos de text mining

- Clasificador de textos basado en palabras
 - Reglas de asociación de conceptos •
- Extracción no supervisada • Reducción de la dimensionalidad y construcción de semánticas

Clasificador de textos basados en palabras

- ¿Qué tenemos?
 - T_i : textos, $1 \leq i \leq N$
 - W_j palabras, $1 \leq j \leq M$
 - M_{ij} palabras por textos = 1 si w_j está en T_i y 0 si no
 - U : L textos clasificados, U subconjunto de T
 - Para cada texto de U sabemos la clase $C(k)$ a la que pertenece
- ¿Qué buscamos?
 - La clase a la que pertenece cada uno de los T_i

Clasificador de textos basados en palabras

- ¿Cómo lo hacemos?
 - Definimos
 $P(j/k)$ probabilidad de encontrar un texto de la clase k que contenga la palabra W_j .
 - Usando el teorema de Bayes podemos calcular la probabilidad de que cualquier T_i pertenezca a la clase k como:

$$P(k/i) = \#U(k)/\#U * \text{Productoria}(P(j/k))$$

- Luego para cada texto T_i me quedo con la clase k que hace máxima $P(k/i)$

Reglas de Asociación para conceptos

- Partimos de una familia de palabras:
 - Perro
 - Cucha
 - Cachorro
 - Mejor amigo del hombre
 - Perra
 - Jauría
- A cada palabra le asignamos un número que mide su “cercanía” a perro:

Reglas de Asociación para conceptos

- A cada palabra le asignamos un número que mide su “cercanía” a perro:
 - Perros 1
 - Cucha .5
 - Cachorro .3
 - Mejor amigo del hombre 1
 - Perra .9
 - Jauría .8
- Sumamos para cada texto las cercanías de todas las palabras y comparamos contra un umbral. Con eso podremos decidir si un texto habla o no de “perros”


Extracción no supervisada

- A partir de la técnica que hemos visto y para un conjunto de documentos y conceptos puedo calcular la matriz de cercanías:
 - T_i : documentos
 - D_j : conceptos
 - $M(i,j)$ cercanía del documento i al concepto D_j
- Aplicamos la técnica de agrupamiento a $M(i,j)$ y podemos agrupar de manera no supervisada los distintos documentos de acuerdo a sus conceptos

Construcción de Semánticas

- Consideramos una nueva matriz $M(j,k)$ que mide la cantidad de documentos que superan un umbral de proximidad fijo para los conceptos j y k simultáneamente.
- Le aplicamos a $M(j,k)$ los conceptos que aprendimos para la construcción de reglas de asociación filtrando las reglas que superen un dado nivel de cobertura y otro de confianza.
- Cada regla que cumpla ambas condiciones relaciona dos conceptos. Esto lo podemos graficar como:

Construcción de Semánticas



Conversión de voz a texto

Conversión de voz a texto

- Problema que se está abriendo.
- Al principio limitado a una voz entrenada
- Todavía entrenamos para mejorar la performance
- El avance se produce por idioma
- Es muy dependiente del poder de procesamiento disponible

¿Cómo elegir una aplicación?

- Necesidad de entrenamiento previo
- Independencia del hablante (enrollment)
- Habla continua vs. Habla discreta
- Robustez
- Tamaño del dominio

¿Qué algoritmos hay disponibles?

- DTW (Dynamic Time Warping) Deformación

Dinámica del Tiempo

- Basados en Modelos Ocultos de Markov
- Redes Neuronales artificiales (Perceptrón Multicapa aplicado a secuencias de eventos temporales)
- Sistemas híbridos (Redes Neuronales + Modelos Markovianos Ocultos)

¿Cómo mido el éxito?

- Fracción de palabras reconocidas (WER): Es la cantidad de palabras que se reconocen (bien o mal) dividida por el total de palabras del texto original.
- Fracción de palabras correctas: Es la cantidad de palabras bien reconocidas dividida por el total de palabras reconocidas.
- Precisión (Accuracy): la precisión contabiliza la cantidad de palabras correctas balanceando las palabras insertadas y las palabras suprimidas.

¿Donde se aplica?

- Dictado verbal • Comandos con interface de voz • Recuperación del texto • Traducción automática • Para generar material para los algoritmos de minería de textos

Cosas que hicimos

- Detección de la edad del hablante •
Detección del sexo del hablante •

Detección de sentimientos • Suplir al
call para temas simples fuera de
horario

Muchas Gracias