

DIPLOMATURA EN CIENCIA DE DATOS

Speech to Text y Text Mining

Speech to Text y Text Mining

Minería de textos:

Trata de obtener información y conocimiento a partir de conjuntos de datos bajo la forma de texto que, en principio, no tienen un orden o no están preparados para transmitir esa información.

Es una técnica de gran valor potencial dada la ingente cantidad de datos existentes bajo la forma de textos no estructurados.

La minería de textos no debe confundirse con la recuperación de información basada en índices creados "Ad Hoc"

Las actividades principales de la minería de textos son:

- Categorización de piezas de texto.
- Extracción de la información incluida en esos textos: hechos, acontecimientos, datos clave, relaciones entre ellos, etc.
- Establecimiento de asociaciones entre los datos extraídos de los textos. □ Extracción automática o supervisada de tópicos o temas

Vamos a cubrir los siguientes algoritmos:

- Clasificador de textos basado en palabras
- Reglas de asociación de conceptos
- Extracción no supervisada
- Reducción de la dimensionalidad y construcción de semánticas

Clasificador de textos basado en palabras:

Tenemos un conjunto de N textos T_i . Cada texto T_i está formado por palabras. Sea W el conjunto de todas las palabras que forman todos los textos.

Sea M el número de elementos del conjunto de palabras W . Cada palabra entonces la llamaremos w_i .

A los efectos de nuestro algoritmo cada texto va a quedar representado por un vector V_i de M posiciones. En cada posición i tiene un 1 si w_i pertenece al texto T_i y un 0 en caso contrario. Tenemos también un subconjunto de textos U contenido en T . Para cada uno de los textos de U que notaremos U_j sabemos la clase $C(j)$ a la que ese texto pertenece.

El problema que enfrentamos es clasificar dentro de C a todos los textos de T a partir de la información brindada por las palabras de los textos.

Vamos a notar $P(i \parallel j)$ a la probabilidad de encontrar la palabra i dentro de uno de los conjuntos de U que pertenece a la clase j .

Es muy fácil calcular $P(i \parallel j)$ como la cantidad de textos U que contienen la palabra i y pertenecen a la clase j dividida por la cantidad total de textos U que pertenecen a la clase j .

Asumiendo que la aparición de cada palabra es independiente de las otras y aplicando el teorema de Bayes la probabilidad de que un texto T pertenezca a la clase j sería:

$$p(j) * \prod_{i=1}^M p(i \parallel j)$$

Donde $p(j)$ es la cantidad de textos U que pertenecen a la clase j dividida por la cantidad de textos U .

Sea ahora:

$$P_{max} = \text{MAX} \left\{ p(j) * \prod_{i=1}^M p(i \parallel j) \quad \forall j \right\}$$

donde j recorre todas las posibles clases en las que podemos clasificar los textos.

Llamamos ahora J_{max} al valor de j que efectivamente produce P_{max} . Justamente, J_{max} es la clase a la cual pertenece el texto T_i .

Ejercicio 12.1

Dentro del campus virtual hay una colección de documentos. Seleccione 20 documentos al azar y clasifíquelos con el siguiente criterio:

- Relato de partido de futbol
- Relato de batalla

MBA Ignacio Urteaga

Diplomatura en ciencia de datos

- Relato de fiesta de casamiento
- Otro

Realice los siguientes pasos:

- Importe los documentos a una tabla de MSSQL Server usando el tutorial "Importación de Documentos a tablas" que está en el campus virtual.
- Genere una tabla con los vectores de palabras usando el tutorial "Identificación y conteo de palabras"
- Cargue las clasificaciones posibles en una tabla de MSSQL Server
- Calcule las probabilidades de aparición de las palabras en los documentos que usted clasificó y guarde el vector en una tabla para su uso posterior.
- Calcule las probabilidades de aparición de las palabras en los documentos por clasificar y guárdelos en una tabla.
- Encuentre para cada documento por clasificar la probabilidad de pertenecer a cada posible clase.
- Guarde en una tabla la probabilidad máxima de pertenecer a una clase de cada elemento por clasificar.
- Identifique que clase tiene la probabilidad máxima. (O sea, clasifique los documentos)

Estos algoritmos basados en el conteo de palabras son también conocidos como algoritmos de sumarización.

Reglas de asociación para conceptos

Un objeto del mundo real puede ser evocado por una multiplicidad de palabras, por ejemplo, para perro podemos pensar en:

- perros
- jauría
- cachorro
- mastín
- cucha

MBA Ignacio Urteaga

- mejor amigo del hombre
- perra
- perras

Todas estas palabras están "cerca" de perro. Podemos pensar que junto con la palabra perro todas evocan al concepto "perro"

Para darle a esto una formulación matemática podemos pensar al concepto como una matriz donde junto a cada palabra ponemos un peso que marca la fuerza de asociación de esa palabra al concepto:

(*perros* *jauría* *cachorro* *mastín* *cucha* *mejor amigo del hombre* *perra* *perras*)
1 1 .5 1 .3 1 1 1)

Podemos entonces calcular el grado de relación existente entre cada texto y cada concepto sumando los pesos de las palabras presentes en cada texto que pertenecen al concepto y dividiendo por el número total de palabras del texto.

Fijamos luego un umbral de significación. Todos los conceptos cuya relación con el texto que supere el umbral se considerará asociado al texto.

Con esto nos quedará para cada texto un vector de atributos. Esos atributos son los conceptos que quedaron asociados al texto.

Con esto estamos en condiciones de aplicar lo que ya sabemos sobre reglas de asociación. Podremos así descubrir que relaciones hay entre los textos a partir de las relaciones que encontremos entre los correspondientes conjuntos de atributos.

Un ejemplo típico sería descubrir que si un texto tiene el concepto A entonces suele incluir también el concepto B. La medición de la calidad de la regla la haríamos en los ya conocidos términos de cobertura y confianza.

Ejercicio 12.2

Considere los conceptos gol y fusil en el contexto de los textos del ejercicio 12.1:

- Cree las matrices correspondientes a ambos conceptos recorriendo las 100 palabras de 4 o más caracteres de longitud más usadas en ellos.
- Calcule el nivel de asociación de cada concepto a cada texto y fije un umbral de significación.

Diplomatura en ciencia de datos

- Escriba los conjuntos de atributos asociados a estos contextos para estos dos conceptos. (Los atributos serán gol, no gol, fusil, no fusil)
- ¿Qué reglas puede extraer con cobertura mayor al 20% y confianza mayor al 80%?

Extracción no supervisada:

Una vez generados los vectores de conceptos para los documentos es posible aplicarles las técnicas de agrupamientos discutidas en agrupamiento.

De esta manera es posible realizar una clasificación no supervisada de los textos introduciendo solamente la cantidad de clases en las que se desea clasificar.

Ejercicio 12.3

Usando los vectores de atributos correspondientes al ejercicio 3.3.2 clasifique en tres clases los documentos del ejercicio 12.1

Estos algoritmos son también conocidos como algoritmos de agrupamiento o "clustering"


Construcción de Semánticas

Hemos visto como se pueden construir vectores con atributos a partir de un conjunto de textos y un grupo de conceptos.

También hemos visto como se pueden relacionar entre sí los conceptos a través de sus vectores de atributos.

Si extraemos todas las reglas con un umbral para su cobertura y otro para su confianza y representamos gráficamente esas relaciones llegamos a lo que se denomina la representación gráfica de una semántica.

Un ejemplo de lo que podemos obtener se parece a:



Hay que notar que el contenido de las relaciones (are, is defined as one as) es repuesto por el investigador mientras que el algoritmo nos provee solamente las flechas que representan las asociaciones encontradas.

Conversión de voz a texto

La conversión del lenguaje humano hablado a texto es uno de los grandes desafíos de la inteligencia artificial.

A la hora de seleccionar una herramienta de conversión de voz a texto habrá que tener en cuenta:

- Necesidad de entrenamiento previo: El sistema viene listo para usar o debe entrenarse para un hablante, conjunto de hablantes y/o lengua y dialecto. Existen grandes diferencias entre los modelos utilizados en telefonía y los utilizados en PC, como los sistemas de dictados.
- Independencia del hablante: El sistema puede reconocer lo dicho por cualquier hablante o queda cautivo del usado en el entrenamiento. Los sistemas de dictado como el sistema Dragon, los modelos son adaptados a un hablante específico mediante a técnica conocida como "enrollment".
- Habla continua vs. Habla discreta: En un principio los sistemas de reconocimiento automático reconocían una palabra por vez. Actualmente los sistemas reconocen habla continúa, lo que constituye un desafío, porque a nivel acústico la señal no presenta pausas.
- Robustez: El sistema sigue funcionando si la fuente de audio incluye ruidos que no confundirían a un humano o se pierde.
- Tamaño del dominio: hay sistemas que son capaces de reconocer las palabras en un contexto reducido (cientos de palabras) mientras que otros trabajan a la par de los humanos (reconociendo miles de palabras). Como ejemplo de dominios podemos mencionar las centrales de auto-atendimiento, que poseen un vocabulario de 200 palabras, un sistema de reconocimiento de reclamos, que puede oscilar entre las 2000 a 5000, mientras que los sistemas especializados en temas médicos pueden superar las 150.000 palabras.

Algoritmos difundidos

MBA Ignacio Urteaga

Se han construido múltiples algoritmos para interpretar el lenguaje humano. Entre otros, se puede mencionar a:

- DTW (Dinamic Time Warping) Deformación Dinámica del Tiempo
- Basados en Modelos Ocultos de Markov
- Redes Neuronales artificiales (Perceptrón Multicapa aplicado a secuencias de eventos temporales)
- Sistemas híbridos (Redes Neuronales + Modelos Markovianos Ocultos)

Los sistemas de reconocimiento automático asumen que la señal del habla es la realización de algún mensaje encodificado como una secuencia de uno o más símbolos.

La operación reversa consiste en reconocer la secuencia de símbolos subyacente dada una emisión hablada.

Para esto, la forma de onda del habla se convierte en una secuencia de vectores discretos de igual duración.

Se asume que la secuencia de vectores forma una representación exacta de la forma de onda sobre la base de la duración cubierta por un simple vector (típicamente de 10 milisegundos, la milésima parte de un segundo).

Se supone que en esta fracción de tiempo la forma de onda del habla es estacionaria, lo cual no es estrictamente cierto, a los fines del reconocimiento es una aproximación satisfactoria.

Las formas de parametrización típicamente utilizadas son el espectro suavizado o coeficientes de predicción lineal más otras representaciones derivadas que aproximan la medición objetiva acústica a la resolución del oído humano.

El rol del reconocedor es realizar un mapeo entre las secuencias de vectores del habla y la secuencia subyacente de símbolos (recordemos que estos símbolos son los fonemas).

La tarea pareciera simple en épocas de estridentes éxitos tecnológicos, pero enfrenta problemas difíciles.

En primer lugar, el mapeo de símbolos al habla no es de uno a uno debido a que diferentes símbolos subyacentes pueden representar sonidos del habla similares.

En el mismo sentido, existe una gran variación en la forma en que los hablantes realizan la cadena del habla debido a la variabilidad ente hablantes, la modalidad del habla, factores ambientales, etc.

En segundo lugar enfrentamos el problema de la segmentación. Los límites entre los símbolos no pueden ser expresados explícitamente a partir de la forma de onda. En este punto no es posible tratar la forma de onda como una secuencia de patrones estáticos concatenados.

En un principio, el problema de la segmentación se sobrellevó mediante reconocedores que reconocían una palabra por vez dado un vocabulario fijo.

Para que se lleve a cabo este mapeo, se crea un modelo que emerge de un entrenamiento estadístico. Cada uno de estas muestras (frames) en que se descompone la cadena acústica se asocia a un fonema de la lengua específica.

En español se puede modelar entre 28 y 32 fonemas y en inglés puede llegar a 56. La asociación entre fonemas y palabras se realiza a través de la construcción de un diccionario fonético, en el cual las palabras son la entrada y la transcripción fonética la salida.

Los diccionarios permiten que una palabra pueda ser transcripta de variadas maneras (ya que existe variación entre los hablantes de una lengua).

El primer problema consiste en identificar los fonemas existentes en la forma de onda. Los sistemas reales trabajan en realidad con las distintas secuencias posibles en que puede asociarse un segmento de la cadena acústica.

Además, los sistemas cuentan con mecanismos de anticipación. Cada vez que una secuencia o probables secuencias de fonemas es reconocido, el modelo evalúa la probabilidad de que esa cadena de fonemas se corresponda con determinada secuencias de palabras.

Las secuencias de palabras más probables están dadas por los modelos de lenguaje, los cuales fueron entrenados sobre corpora de textos afines al dominio de aplicación del sistema.

Esto permite reducir la dimensionalidad en la búsqueda de secuencias de palabras posibles. Imaginemos la combinación de cualquier palabra con cualquier otra en un vocabulario de 64000 palabras, como ocurre frecuentemente en los escenarios del reconocimiento de habla. La cantidad de posibles cadenas de habla serían sideral.

Para ello el modelo del lenguaje permite restringir las secuencias para poner en primer lugar a aquellas más probables y a las secuencias posibles.

Mejora tanto la velocidad en la búsqueda de secuencias como restringe drásticamente el crecimiento exponencial de combinaciones.

Las secuencias reconocidas también permiten guiar al reconocedor al nivel fonémico, porque va indicando cuáles son las secuencias de fonemas posibles de acuerdo a la lista de secuencias posibles de palabras que predice.

Este mecanismo agiliza el reconocimiento y mejora sustancialmente la tasa de reconocimiento. Su implementación data de la última década.

Los sistemas de reconocimiento tienen mayor dificultad en reconocer las palabras de función, tales como las preposiciones, conjunciones, conectores y artículos, que son pronunciados con menor amplitud, con mayor velocidad de elocución y muchas veces con supresión de material fonético.

La mayor dificultad también se encuentra al principio de las emisiones, ya que el modelo cuenta con menos evidencia para computar la probabilidad de ocurrencia de tal o cual palabra.

Medición del éxito

El éxito de un sistema de reconocimiento del habla se mide en dos dimensiones principales:

- Fracción de palabras reconocidas (WER): Es la cantidad de palabras que se reconocen (bien o mal) dividida por el total de palabras del texto original.
- Fracción de palabras correctas: Es la cantidad de palabras bien reconocidas dividida por el total de palabras reconocidas.
- Precisión (Accuracy): la precisión contabiliza la cantidad de palabras correctas balanceando las palabras insertadas y las palabras suprimidas.

Para evaluar la precisión de un sistema debe transcribirse a mano un conjunto de frases usado como referencia contra el cual se evalúa el comportamiento del sistema de reconocimiento.

Otra cualidad muy importante es la velocidad a la que realiza la decodificación. Dependiendo del músculo computacional disponible puede trabajar en tiempo real o puede tardar varias veces el tiempo de la emisión del hablante.

Entre otros usos el reconocimiento de voz sirve para:

- Dictado verbal
- Comandos con interface de voz
- Recuperación del texto
- Traducción automática

Ejercicio 12.4

Utilizando la herramienta Sphinx, cuyo tutorial de instalación se encuentra en el campus virtual procesar las grabaciones de una clase y convertirla a texto.

Luego realizar un mapa de conceptos como el descrito en el último punto de la Unidad de minería de textos.