

DIPLOMATURA EN CIENCIA DE DATOS

Bayes avanzado y regresión logística

Introducción:

Ya hemos visto la regresión lineal. En esta unidad nos proponemos explorar varios métodos bayesianos:

- Regresión lineal bayesiana
- Regresión logística
- Regresión logística bayesiana
- Red bayesiana

Regresión lineal bayesiana:

Cuando se estudia con detalle la regresión lineal es necesario hacer hipótesis acerca de la distribución de los errores.

Para llegar a las fórmulas que hemos visto en las primeras unidades asumimos casi sin darnos cuenta que esos errores seguían una distribución normal.

¿Tiene necesariamente que ser así?


Tristemente la respuesta es que no, que muchas veces los desvíos siguen una distribución distinta y eso impacta en el tamaño y la forma del intervalo donde vamos a encontrar con una cierta probabilidad tanto la pendiente como la ordenada al origen.

Entonces podemos tratar de validar el modelo utilizando la distribución predictiva posterior.

Tomaremos para eso subconjuntos de los datos y calcularemos para cada uno de ellos la pendiente y la ordenada al origen.


Vamos a desarrollar un ejemplo para tratar de entender cómo usarla.

Considero los datos de una inmobiliaria que tiene, en su base de datos 100 valoraciones y necesita saber que casos tienen más probabilidades de estar mal valorados (o sea, comportarse como outliers)



```
> library(LearnBayes)
> setwd("D:/Users/ignacio/Dropbox/Instituto para el uso ético de la ciencia de datos/Cursos/Diplomatura en Ciencia$
> deptos <- read.csv("Inmobiliarial.csv",sep=";")
> pairs(deptos[,2:5])
> |
```

Y obtenemos:



Vemos una correlación bastante definida entre el área que ocupa el departamento y el precio de venta. (Qué novedad!)

Pero, como esta dependencia domina nos impide ver si los otros parámetros influyen y cómo.

Empezamos entonces por construir una regresión lineal para tratar de predecir el precio como función del área, la distancia y la antigüedad


Realizamos la predicción para calcular así el error que se comete y poder graficar su distribución:

```

RGui (64-bit) - [R Console]
Archivo Editar Visualizar Misc Paquetes Ventanas Ayuda
> p <- predict(ml,newdata=deptos)
> err <- p - deptos$Precio
> hist(err)
> |

```

Nos da:



Nos quedan dudas de que la distribución sea simétrica.

Ahora nos toca construir un modelo de regresión bayesiana. Para eso recurrimos a la función `blinreg()`


```


RGui (64-bit) - [R Console]
Archivo  Editar  Visualizar  Misc  Paquetes  Ventanas  Ayuda


> theta <- blinreg(deptos$Precio,cbind(1,deptos$Area,deptos$Distancia,deptos$Antig.edad),5000)
> apply(theta$beta,2,median)
      X1      X2      X3      X4
22315.69723 1329.03999 -27.00417 -1896.10826
> |

```

Ahora podemos verificar si la distribución de los 5000 parámetros que hemos obtenido para las pendientes son simétricos o no:







Para ver la distribución de la varianza hacemos:


```

RGui (64-bit) - [R Console]
Archivo  Editar  Visualizar  Misc  Paquetes  Ventanas  Ayuda
[Icons: File Explorer, Recent Files, Save, Print, Run, Stop, etc.]

> hist(theta$sigma^2,main="Varianza",xlab=expression(sigma^2))
> |

```

Y nos da:



Tenemos que realizar ahora la estimación puntual para los parámetros:

Los mejores estimadores de los parámetros resultan entonces:

Parámetro	Valor
Ordenada al origen	22315
Pendiente área	1329
Pendiente distancia	-27
Pendiente antigüedad	-1896


Ahora estamos en condiciones de discutir si un punto es o no un “outlier” Para eso necesitamos saber el precio, el área, la distancia y la antigüedad.

Supongamos que tenemos varios departamentos cuyos precios son:

Departamento	Precio	Área	Distancia	Antigüedad
A	200000	120	500	0
B	150000	150	800	5
C	200000	200	200	2
D	105000	80	500	3

¿Serán casos raros?

Utilizamos `blinregexpected()` para calcular la distribución de precios para cada uno:




```

> xA <- c(1,120,500,0)
> xB <- c(1,150,800,5)
> xC <- c(1,200,200,2)
> xD <- c(1,80,500,3)
> X <- rbind(xA, xB, xC, xD)
> media.precio <- blinregexpected(X, theta)
> hist(media.precio[,1], main="xA", xlab="Precio")
> |

```

Y obtenemos:




¿Dónde caen los 200.000? Completamente a la derecha de la distribución. Resultará claramente un caso raro.

¿Cuán raro?


En este caso concreto los 200.000 nos quedan tan afuera de la distribución que no podemos estimar cuan improbable es este caso.

Sigamos recorriendo los casos:




B también cae fuera de la distribución, ahora se trata de un caso de un precio demasiado barato.

Algo similar ocurre para C:



Mientras que para D:



Para ver la probabilidad de que me de menos de 105.000 calculo:

```

RGui (64-bit) - [R Console]
Archivo  Editar  Visualizar  Misc  Paquetes  Ventanas  Ayuda

> pD <- media.precio[,4]
> length(which(pD<105000))/length(pD)
[1] 0.0262
> |

```

Me cae dentro de los límites de la distribución pero también es un caso raro.

Con esto puedo establecer un criterio objetivo para juzgar cuando estoy frente a un caso raro o no por el simple expediente de poner un límite a cuan improbable estoy permitiendo que una situación sea e igual siga considerándola normal.

Es pertinente realizar una aclaración. Que no caso sea raro no implica que el negocio deba olvidarse de el. Al contrario. Podría ser que tuviéramos una inmobiliaria

especializada en gangas, que miraría los muy baratos (con los recaudos legales y arquitectónicos del caso) o una especializada en el lujo que buscaría los muy caros.

La estadística llega a señalar la rareza del caso. Su realidad comercial deberá abreviar de otras aguas.

Regresión logística

Antes de meternos con la regresión logística bayesiana tenemos que considerar la regresión logística simple.

Cómo siempre nos planteamos para cada algoritmo cuales son los parámetros de entrada y cuál es la salida buscada.

Como se trata de un caso de aprendizaje supervisado vamos a tener una muestra de la que conoceremos los atributos y el resultado mientras que para el resto del universo vamos a conocer solo los atributos.

Una particularidad es que la salida buscada es, para el caso de regresión logística es una variable cualitativa. Por este motivo podemos pensar en la regresión logística como un algoritmo clasificador.

Supongamos que queremos clasificar casos en urgentes y no urgentes sobre la base de unos pocos atributos relacionados con las constantes vitales de los pacientes.

Nuestras dos clases serán:

0 = No necesita atención urgente

1 = Si necesita atención urgente

Intuitivamente lo que vamos a tratar de hacer es calcular la probabilidad de que un paciente necesite o no atención urgente.

Ahora podríamos calcular la probabilidad utilizando la misma técnica que la regresión lineal.

Nuestros datos se parecen a:

Caso	Temperatura	Tensión Art. Alta	Tensión Art. Baja	Saturación O2	Pulso Cardíaco	Urgente
1	37,3	16,7	12,6	90,6	69,5	SI
2	36,0	15,6	15,5	97,7	92,3	SI

La variable categórica que queremos predecir es Urgente.


Ahora bien, en vez de predecir la probabilidad con una regresión lineal (que por necesidad va a ir de menos a más infinito) vamos a predecir el valor de la función logística inversa: `logit()`

$$\text{logit}(P(\text{urgente})) = a + b * T + c * TH + d * TL + e * S + f * P$$

Donde:

- T: temperatura
- TH: tensión arterial alta
- TL: tensión arterial baja
- S: saturación de O2
- P: Pulso cardíaco


La forma de la función logística es:



Podemos obtenerla haciendo:

```
RGui (64-bit) - [R Console]
Archivo Editar Visualizar Misc Paquetes Ventanas Ayuda
> x <- -5000:5000
> x <- x/100
> y <- 1/(1+exp(-x))
> plot(x,y, type = 'l')
> |
```


Para graficar su inversa alcanza con invertir los ejes, por lo tanto la forma de la función `logit()` es:



El dominio va de 0 a 1 (como corresponde a una buena probabilidad) mientras que la imagen va de menos a más infinito (como corresponde a una recta)


Sin ahondar más en el aspecto matemático vamos a ver como lo implementamos en R

Empezamos por cargar los datos y verificar que todo sea correcto:




```
> setwd("D:/Users/ignacio/Dropbox/Instituto para el uso ético de la ciencia de datos/Cursos/Diplomatura $")
> h <- read.csv("RegresiónLogistical.csv", sep=";")
> head(h)
  Caso Temperatura Tensi.n.Art..Alta Tensi.n.Art..Baja Saturaci.n.O2 Pulso.Card.aco Urgente
1    1      36.0      14.3          8.5      99.9      89.2      SI
2    2      36.1      12.0          4.7      97.0      82.0      SI
3    3      36.1      12.0          5.6     100.0      86.0      SI
4    4      36.7      15.6          9.1      99.0      82.9      SI
5    5      36.0      12.0          4.3     100.0      60.1      NO
6    6      36.2      12.0          4.0      95.1      84.8      SI
```

Notamos que Urgente es un dato de tipo carácter. Eso nos puede traer algún problema así que vamos a asegurarnos que sea un vector y a convertirlo a numérico sin perder la esencia del dato:




```
> h$Urgente <- as.vector(h$Urgente)
> u = ifelse(h$Urgente == "SI", 1, 0)
> h <- cbind(h, u)
> |
```

Ahora vamos a dividir nuestros datos en las dos partes desiguales típicas para usar en el entrenamiento y en la prueba:



```
> x <- runif(nrow(h))
> train <- h[which(x<.7),]
> test <- h[which(x>=.7),]
> |
```

Nos toca ahora construir el modelo predictivo y generar la predicción correspondiente sobre el conjunto de prueba:




```

> g <- glm(formula = u ~ Temperatura + Tensi.n.Art..Alta + Tensi.n.Art..Baja + Saturaci.n.O2 + Pulso.Car$
> p <- predict(g, newdata = test)
>

```

Las predicciones, como esperábamos varían en forma continua. Para llevarlas a las categorías 0 y 1 aproximamos al número más cercano y luego calculamos la matriz de aciertos y errores:



```

> p <- floor(p+.5)
> m <- matrix(nrow=2, ncol=2, 0)
> for(i in 0:1) {
+   for(j in 0:1) {
+     m[i+1,j+1] <- length(which(p==i & test$u==j))
+   }
+ }
> m
      [,1] [,2]
[1,]    9    3
[2,]    8   29
>

```

Vemos que 9 veces acertamos la no urgencia, 29 veces acertamos la urgencia y, en total, hemos cometido $8+3 = 11$ errores.

Regresión logística bayesiana

Ahora que hemos visto la regresión logística estamos en condiciones de encarar la regresión logística bayesiana.

Se trata de aplicar el mismo truco que en la regresión lineal para detectar outliers en una regresión logística.

Los interesados en asomarse a la dificultad matemática del problema pueden consultar en:

<https://www.youtube.com/watch?v=aCNqfMoLLG8>

Allí encontrarán un ejemplo de implementación utilizando el paquete R2jags.

Redes Bayesianas

Una red bayesiana es un grafo orientado donde cada nodo tiene información de probabilidades.

Como hablamos de un grafo orientado la red está compuesta por arcos que van de un nodo padre a un nodo hijo.

Una red bayesiana cuenta con un conjunto de variables aleatorias que describen el estado de los diferentes nodos.

La información de probabilidad contenida en los nodos indica cual es la probabilidad de que ocurra cada estado en un nodo hijo dado el estado en el cual se encuentran los padres.

El grafo correspondiente a una red bayesiana es, por definición, un grafo acíclico.

El proceso por el cual se propaga la información a lo largo de la red se llama inferencia.

Cada nodo posee una distribución de probabilidad condicional. Esto es conoce la probabilidad de cada uno de sus estados en función de los estados de sus padres.

Consideremos una casa en una zona sísmica que cuenta con una alarma.

Si se produce un robo hay un 80% de probabilidades de que suene la alarma.

Si suena la alarma hay un 70% de probabilidades de que la empresa que monitorea la alarma contacte al propietario.


Si hay un terremoto de grado 6 o superior entonces hay un 60% de probabilidades de que suene la alarma. Como estarán sonando muchas alarmas en la zona la probabilidad de recibir la llamada de la empresa de monitoreo es un 10%.

Si hay un terremoto de grado 6 o superior hay un 90% de probabilidades que aparezca en las noticias

Empezamos por los hechos independientes:



Ahora les agregamos las posibles consecuencias:



Tenemos varios caminos o historias posibles:

Robo -> Alarma -> Llamada

Terremoto -> Noticia

Terremoto -> Alarma -> Llamada

Terremoto -> Alarma + Noticia -> Llamada

Terremoto -> Alarma + Noticia

Todas son historias posibles pero, quizá no son todas las historias posibles.

¿Cómo construimos una red bayesiana?

El primer paso es listar todas las variables relevantes para el problema.

Luego hay que distribuirlas en forma de red siguiendo el orden de causalidad conocida.

Aquí conviene señalar que la facilidad con la que la red representará nuestro problema depende de una buena elección del orden.

Si tuviéramos dudas sobre la causalidad porque puede funcionar en dos sentidos o porque nos es desconocida podemos probar con ambos diseños.

Hay tres usos principales del proceso de inferencia:

Diagnóstico:

He recibido la llamada telefónica de la empresa de monitoreo. ¿Cuál es la probabilidad de que haya habido un robo?

Predicción:

Se ha dado un robo. ¿Cuál es la probabilidad de que reciba la llamada de la empresa de monitoreo?

Intercausal

He recibido la llamada telefónica de la empresa de monitoreo. ¿Cuál es la probabilidad de cada causa?

Implementación en R:

Veamos la red ASIA citada en: <https://www.datanalytics.com/2013/11/19/la-red-asia/>

Empezamos por los hechos duros:

- Visita a Asia
- Fumador


A partir de ellos tenemos cuatro posibles diagnósticos:

- Tuberculosis
- Cáncer de pulmón
- Tuberculosis+Cáncer de pulmón
- Bronquiolitis

Y dos resultados observables a partir de los diagnósticos:

- Radiografía compatible con tuberculosis
- Dificultad para respirar

Si los organizamos en forma gráfica, siempre siguiendo un orden causal, tenemos:



Las probabilidades elementales de cada hecho inicial son:

P(vistar Asia): $A = .01$

P(fumador): $S = .5$

Pasamos a las probabilidades condicionales:

$P(\text{Tuberculosis/Visitó Asia}) : T = 0.05$

$P(\text{Tuberculosis/No visitó Asia}) : 0.01$

$P(\text{Bronquiolitis/Fumador}) : B = 0.6$

$P(\text{Bronquiolitis/No fumador}) : 0.3$

$P(\text{Cáncer de pulmón/Fumador}) : C = 0.1$

$P(\text{Cáncer de pulmón/No Fumador}) : 0.01$

$P(\text{Tub o Cancer/Tub, Cancer}) = 1$

$P(\text{Tub o Cancer/Tub, -Cancer}) = 1$

$P(\text{Tub o Cancer/-Tub, Cancer}) = 1$

$P(\text{Tub o Cancer/-Tub, -Cancer}) = 0$

$P(R/E) = 0.98$

$P(R/-E) = 0.05$

$P(D/E, B) = 0.90$

$P(D/E, -B) = 0.70$

$P(D/-E, B) = 0.80$


$P(D/-E, -B) = 0.10$

Para aplicar la librería gRain tendremos que instalar un montón de dependencias que no se encuentran en los espejos CRAN.

El primer paso es asegurarnos que estamos corriendo una versión compatible de R. La 3.5 no alcanza. La 3.6 quizá. Lo que sigue fue hecho con R v 4.0

Los vínculos a mi dropbox los tienen en el pdf correspondiente dentro del campus virtual.

Para armar la red hacemos:




```

> yn <- c("yes", "no")
> a <- cptable(~ asia, values = c(1, 99), levels = yn)
> t.a <- cptable(~ tub + asia, values = c(5, 95, 1, 99), levels = yn)
> s <- cptable(~ smoke, values = c(5,5), levels = yn)
> l.s <- cptable(~ lung + smoke, values = c(1, 9, 1, 99), levels = yn)
> b.s <- cptable(~ bronc + smoke, values = c(6, 4, 3, 7), levels = yn)
> x.e <- cptable(~ xray + either, values = c(98, 2, 5, 95), levels = yn)
> d.be <- cptable(~ dysp + bronc + either, values = c(9, 1, 7, 3, 8, 2, 1, 9), levels = yn)
> e.lt <- ortable(~ either + lung + tub, levels = yn)
>
> plist <- compileCPT( list(a, t.a, s, l.s, b.s, e.lt, x.e, d.be))
> BN <-grain(plist,smooth=0)
>

```

Dentro de BN tenemos ya guardada nuestra red bayesiana:

Con `plot(BN)` vemos:



Una vez que hemos creado la red y la hemos cargado con las probabilidades podemos usarla en un sentido o en otro.

Por ejemplo, si quisiéramos preguntarnos: ¿Cuál es la probabilidad de que alguien haya viajado a Asia dado que exhibe dificultad para respirar y no es un fumador?

```

RGui (64-bit) - [R Console]
Archivo Editar Visualizar Misc Paquetes Ventanas Ayuda

> tmp1 <- setFinding(BN, nodes = c("smoke","dysp"), states = c("no","yes"))
> querygrain(tmp1,nodes=c("asia"))
$asia
asia
      yes      no
0.0105528 0.9894472
> |

```

Los que quieran ver más sobre este tema pueden recurrir a:

<https://fdoperez.webs.ull.es/doc/Conocimiento5.pdf>