



INSTITUTO
Data Science

SERIES TEMPORALES



¿Qué son las series temporales?

Una serie temporal es una colección de observaciones de una variable aleatoria tomadas en forma secuencial a medida que transcurre el tiempo.

Se aplican a:

- Cantidad de personas en una cola
- Cantidad de casos de gripe
- ETC



¿Cómo las tratamos?

- No pueden asumirse como independientes entre si.
- Hay que tener en cuenta el orden en que los datos aparecieron.

¿Qué nos proponemos?

- Descripción
- Predicción



Clasificaciones

- Por el tipo de espaciado
 - Discreta
 - Continua
- Por la aleatoriedad de los resultados:
 - Determinística
 - Estocástica



Un ejemplo por favor

Series determinísticas:

- Tendencia lineal: consiste en la extrapolación hacia el futuro. La variable objeto del estudio es una función determinista del tiempo.

$$X_t = a + b t$$

- Medias móviles: la variable en el momento t es un promedio simple de un determinado número de valores pasados.

$$X_t = (X_{t-1} + + X_{t-12})/12$$




Un ejemplo por favor (cont.)


Series estocásticas:

- Cantidad de gripes por día:
 - Los engripados contagian, luego $G(n+1)$ depende de $G(n)$
 - La probabilidad de contagio depende del clima, luego tengo una periodicidad
 - Los contagios dependen de eventos sociales (vacaciones de invierno, feriados, etc)



Gripes






ARIMA

- Auto Regresive Integrated Mobile Average
- Funciona cuando se cumplen las condiciones de estacionareidad.
- Lo verificamos con el test de Dick y Fuller:
 - Media constante
 - Varianza constante
 - Frecuencia constante
- Y si no... DESCOMPOSICIÓN




¿Por que puede fallar un modelo?

- Revisar que la media es invariante



Stationary series




Non-Stationary series

- Revisar que la dispersión es invariante
- Revisar que la autocorrelación retardada es invariante




¿Por que puede fallar un modelo?

- Revisar que la media es invariante
- Revisar que la dispersión es invariante



Stationary series




Non-Stationary series

- Revisar que la autocorrelación retardada es invariante




¿Por que puede fallar un modelo?

- Revisar que la media es invariante
- Revisar que la dispersión es invariante
- Revisar que la autocorrelación retardada es invariante



Stationary series



Non-Stationary series



Separamos


$$S(t) = L(t) + P(t) + R(t)$$

Donde:




L: representa la tendencia a largo plazo

P: representa la parte periódica o estacional

R: da cuenta del comportamiento aleatorio



Separando componentes



Separando componentes

En R:

```
library('ggplot2')  
library('forecast')  
library('tseries')
```

```
// creo el objeto time series
```

```
ventas_ts <- ts(h$Venta)
```

```
// limpio la serie temporal
```

```
ventas_ts_clean <- tsclean(ventas_ts)
```



Separando componentes

En R: (cont.)

```
// suavizo por semana y por ciclo
```

```
h$Ventas_ma7 <- ma(ventas_ts_clean, order = 7)
```

```
h$Ventas_ma28 <- ma(ventas_ts_clean, order = 28)
```

```
// Separo en componentes usando un modelo aditivo
```

```
// si quiero usar un modelo multiplicativo
```

```
// allow.multiplicative.trend=TRUE como parámetro dentro de stl
```

```
Venta_ma <- ts(na.omit(h$Ventas_ma7), frequency = 28)
```

```
decomp <- stl(Venta_ma, s.window="periodic")
```


```
deseasonal_Venta <- seasadj(decomp)
```



¿Qué pasa si tengo múltiples períodos?

- Para superar los multiples períodos
 - TBATS / MSTs
 - Forecast
- Limitación:
 - Parte temporal acíclica







Vamos a separar

```
library(lubridate)
library("forecast")
library("tseries")
h <- read.csv("simulador.csv",sep=";")
y.msts <- msts(h$Total, seasonal.periods=c(7,30.4,365.25))
fit <- tbats(y.msts, use.box.cox=NULL, use.parallel=TRUE, num.cores = NULL,
use.trend=NULL, use.damped.trend=NULL, use.arma.errors=TRUE,
model=NULL)
components <- tbats.components(fit)
plot(components)
```




components




Veamos los residuos

checkresiduals(fit)



Y, por fin, la predicción

```
fc <- forecast(fit)
```



¿Cómo seguimos?

- Vamos a tomar un ejemplo comercial real
- Va a tener ciclos irregulares
- Va a tener eventos regulares (anuales) en los ciclos
- Vamos a tratar de predecir como hasta ahora
- Vamos a renormalizar para matar las irregularidades en los ciclos
- Vamos a predecir a ciclo completo y a ciclo parcial
- Vamos a combinar ambas predicciones




Pasos para ajustar series temporales

- Ver los datos
- Probar si la serie temporal es estacionaria
- Convertir la serie temporal en estacionaria
- Encontrar los parámetros para el modelo ARIMA
- Construir el modelo ARIMA
- Hacer las predicciones



Veo la serie temporal de ventas



Para testear la estacionareidad

```
library(tseries)  
adf.test(diff(h$Cantidad), alternative="stationary",k=0)
```

Augmented Dickey-Fuller Test

```
data: diff(h$Cantidad)  
Dickey-Fuller = -27.467, Lag order = 0, p-value = 0.01  
alternative hypothesis: stationary
```

Warning message:

```
In adf.test(diff(h$Cantidad), alternative = "stationary", k = 0) :  
  p-value smaller than printed p-value
```



Para testear la estacionareidad

```
library(tseries)  
adf.test(diff(h$Cantidad), alternative="stationary",k=0)
```

Augmented Dickey-Fuller Test

```
data: diff(h$Cantidad)  
Dickey-Fuller = -27.467, Lag order = 0, p-value = 0.01  
alternative hypothesis: stationary
```

Warning message:

```
In adf.test(diff(h$Cantidad), alternative = "stationary", k = 0) :  
p-value smaller than printed p-value
```



¿Cómo convertimos una serie en estacionaria?

- Remover la tendencia

$$y(t) = (\text{mean}(x(t)) + \text{trend} * t)$$

Luego modelar:
 $x(t) - y(t)$


- Diferenciar
modelar:

$$x(t) - x(t-1)$$




Hagamos el ajuste


```
ts <- ts(h$Cantidad)  
fit <- auto.arima(ts,seasonal=FALSE)  
plot(ts)  
lines(fitted(fit),col=2)
```




¿Cómo luce la interpolación?



¿Cómo luce la interpolación?



NO! ¿Qué pasa cuando no se reconocen los ciclos por su variabilidad?



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

¿Cuán bueno es el ajuste?

```
err <- sum(((ts-fitted(fit))/fitted(fit))^2)/nrow(v)
```

```
err
```

```
[1] 3.89986
```



Vamos a acumular por ciclo:


```
PUNTOSAC <- numeric(nrow(v))
PUNTOSAC[] <- 0
ac <- 0
CD_CICLO <- v$CD_CICLO[1]
for(i in 1:nrow(v)) {
  if (CD_CICLO == v$CD_CICLO[i]) {
    ac <- ac + v$PUNTOS[i] }
  if (CD_CICLO != v$CD_CICLO[i]) {
    CD_CICLO <- v$CD_CICLO[i]
    ac <- v$PUNTOS[i] }
  PUNTOSAC[i] <- ac }

v <- cbind(v,PUNTOSAC)
```




¿Y si los períodos también son función del tiempo?

```
plot(v$PUNTOSAC,type="l")
```



¿Y si los períodos también son función del tiempo?

```
plot(v$PUNTOSAC,type="l")
```



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Repito el ajuste:

```
ts <- ts(v$PUNTOSAC)
```

```
fit <- auto.arima(ts,seasonal=FALSE)
```


```
plot(ts)
```

```
lines(fitted(fit),col=2)
```




¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

¿Cuán bueno es el ajuste?

```
err <- sum(((ts-fitted(fit))/fitted(fit))^2)/nrow(v)
```

```
err
```

```
0.6425071
```



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

¿Cuán bueno es el ajuste?

```
err <- sum(((ts-fitted(fit))/fitted(fit))^2)/nrow(v)
```

```
err
```

```
0.6425071
```

ES MEJOR!!!



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Vamos a tratar de predecir:

```
fc <- forecast(fit,100)
```


```
plot(fc)
```



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:


Forecasts from ARIMA(2,0,1) with non-zero mean



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Forecasts from ARIMA(2,0,1) with non-zero mean



NO PREDICE NADA!



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Pruebo con tbats

```
y.msts <- msts(v$PUNTOSAC, seasonal.periods=c(7,30.4,365.25))
```

```
fit <- tbats(y.msts, use.box.cox=NULL, use.parallel=TRUE, num.cores =  
NULL, use.trend=NULL, use.damped.trend=NULL,  
use.arma.errors=TRUE, model=NULL)
```



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Separo los componentes:


```
components <- tbats.components(fit)
```

```
plot(components)
```



¿Y si los períodos también son función del tiempo?


Caso real empresa de cosméticos:



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

components




**NO PUDO
RECONOCER**



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:
checkresiduals(fit)




¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Y la predicción:

Forecasts from BATS(0.376, {0,0}, 0.8, -)




¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Y la predicción:

Forecasts from BATS(0.376, {0,0}, 0.8, -)



NO PREDICE NADA



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Renormalización:

- Fracción de avance sobre la venta total del ciclo
- Fracción de avance del ciclo



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

La conversión por SQL va aparte...

```
h <- read.csv("interpolacion.csv",sep=";")
```



¿Y si los períodos también son función del tiempo?


Caso real empresa de cosméticos:

```
t <- ts(h$fAcInterpolada,frequency = 21)
lt <- ts(log(h$fAcInterpolada),frequency=21)
decomp <- stlm(lt,s.window = "periodic")
ta <- periodic+trend+remainder
plot(lt)
lines(ta,col=2)
```




¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Pruebo con tbats

```
y.msts <- msts(h$fAcInterpolada, seasonal.periods=c(21,357))
```

```
fit <- tbats(y.msts, use.box.cox=NULL, use.parallel=TRUE, num.cores =  
NULL, use.trend=NULL, use.damped.trend=NULL,  
use.arma.errors=TRUE, model=NULL)
```



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Separo los componentes:


```
components <- tbats.components(fit)
```

```
plot(components)
```




¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Veamos la predicción

```
fc <- forecast(fit,100)
```


```
plot(fc)
```



¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Forecasts from TBATS(1, {2,1}, -, {<21,1>, <357,1>})




¿Y si los períodos también son función del tiempo?

Caso real empresa de cosméticos:

Como se puede seguir:

- Pasar logaritmico
- Verificar los períodos




¿Qué intentamos?

- ~~ARIMA y Fourier:~~
 - En general manejan bien ciclos más tendencias.
 - Asumen ciclos de longitud fija
- Tbats y MSTs con descomposición logarítmica + Renormalización
 - Cambiamos las unidades temporales a la fracción recorrida del ciclo actual
 - Cambiamos las unidades vendidas a la fracción acumulada del ciclo actual

Eureka!



Otro camino...



¿El error no es muy grande?

- El gráfico engaña...
- A los 7 días:
 - el error del promedio es 5%
 - El 68 % de los casos caen entre el -2% y el +12%
 - El 95 % de los casos caen entre el -9% y el +19%



¿El error no es muy grande? (cont.)

- A los 14 días:
 - el error del promedio es 2%
 - El 68 % de los casos caen entre el -14 % y el +10%
 - El 95 % de los casos caen entre el -26% y el +22%
- De esta manera se pueden hacer 100 predicciones sobre varias organizaciones y validar si los errores se acomodan a la predicción



¿Cómo funciona?

- **$P = A * (2 * F / (1 + F))^{2.85}$**
- Donde:
 - P: predicción al final del ciclo
 - A: Puntos vendidos a hoy
 - F: fracción del ciclo ya transcurrido hoy



Conclusiones

- Algoritmos hay muchos
- Predecir es difícil
- Hay que ser consciente de las limitaciones de cada algoritmo
- Hay que probar las predicciones varias veces
- Hay predicciones que se comen su propio éxito



MUCHAS GRACIAS

¿Alguna pregunta?





INSTITUTO
Data Science